

CHEMAI PREDICT THE CURE

Прогнозирование противовирусной активности молекул

Команда №8 «Самые_лучшие»

Состав команды:

Лазарев Виктор
Дублин Кирилл
Матешева Анастасия
Носульчак Елена

Постановка задачи и данные

Что предсказываем

IC50 (мкМ) — концентрация, подавляющая 50% вируса

CC50 (мкМ) — концентрация, токсичная для 50% клеток

SI = CC50 / IC50 — индекс селективности

Обучающая выборка: 751 молекула, 214 признаков


Тестовая выборка: 250 молекул, 211 признаков

Метрика: усреднённый RMSE по трём таргетам

Главные сложности

- Скошенные распределения (тяжёлые правые хвосты)
- Выбросы: IC50 — 107 из 751 по IQR
- Пропуски в 12 колонках (зарядовые дескрипторы, BCUT2D)

Распределение таргетов



Исследовательский анализ данных



Трансформация

log1p для IC50 и CC50

Симметризация распределений,
стабилизация дисперсии

Удалены **index** и 15 константных
fr_-признаков

Пропуски не заполняли —
XGBoost сам обрабатывает NaN

Всего fr-признаков: 85

15 признаков оказались
константными (всегда 0) —
соответствующие группы
отсутствуют во всех молекулах
датасета. Эти признаки не несут
полезной информации и **удалены**
из обучающей выборки

SI = CC50 / IC50

SI **не обучаем** напрямую
Вычисляем как отношение CC50 к
IC50

Упрощает задачу и снижает
ошибку переноса

Защита от деления на ноль: IC50
< 0.001 → 0.001

Отбор признаков, взвешивание, базовая модель

CHEMAI PROJECT



Отбор признаков

IC50 — 50 лучших признаков

CC50 — 30 лучших признаков

Лишние признаки добавляют шум и замедляют обучение

Кросс-Валидация 5 фолдов

Для каждого варианта обучаем основную модель с настроенными параметрами

Лучший результат:

IC50: 50 признаков (RMSE 1.4555)

CC50: 30 признаков (RMSE 1.2066)

Базовая модель (baseline)


База: max_depth=4, lr=0.03,
n_estimators=300

Сетка: subsample, colsample_bytree,
reg_alpha, reg_lambda

ИТОГ: на этом этапе получили результат 287 баллов на Kaggle. Взяли за baseline

График выбросов

CHEMAI PROJECT





IC50: модель путает большие и малые значения — 972 предсказывает как 38 (ошибка в 25 раз), а 33 как 688 (ошибка в 21 раз). При этом реальный диапазон IC50: от 0.01 до 4095.

CC50: главная проблема — соединения с реальным $CC50 \approx 1$, которые модель предсказывает как 25–265. Шесть из десяти худших ошибок — это когда истина ~ 1 , а предсказание в 25-265 раз выше. Модель систематически завышает малые значения CC50.

Решение: удаляем топ-5 худших с каждого таргета

Распределение весов по квартилям

CHEMAI PROJECT



Вывод: края распределения (0-25% и 75-100%) получают в 3-5 раз больший вес, чем середина. Особенно выделяются малые значения CC50 (вес 2.01) — именно на них модель ошибалась сильнее всего (предсказывала 265 вместо 1). Взвешенное обучение заставляет модель уделять внимание этим редким, но важным для фармы экстремальным случаям, а не оптимизировать только «среднюю» молекулу



Из топ-20 важности IC50 взяли два сильных признака: NumHDonors (2-е место) и VSA_EState8 (4-е место).

Перемножили: $HDonors_x_VSA8 = NumHDonors \times VSA_EState8$ — по химическому смыслу это «полярная поверхность, способная к водородным связям».

Новый признак занял **1-е место по важности** для обоих таргетов (IC50: 0.144, CC50: 0.151).

Однако при добавлении в модель RMSE на кросс-валидации не улучшился, а на Kaggle результат ухудшился. Видимо XGBoost самостоятельно находит такие взаимодействия через разбиения в деревьях, и готовый признак не добавляет новой информации, а лишь смещает фокус модели.

Вывод: признак не включён в финальную модель, дальнейший инжиниринг остановлен — деревья сами справляются с комбинациями.

Подбор параметров для финальной модели шаг 1



Лучшие параметры GridSearchCV				
Таргет	subsample	colsample_bytree	reg_alpha	reg_lambda
IC50	0.7	0.7	0.1	1
CC50	0.6	0.7	0.3	1

После подбора гиперпараметров через GridSearchCV (5 фолдов, 180 комбинаций) мы снизили subsample (0.6–0.7 вместо 0.8) и colsample_bytree (0.7 вместо 0.8). Теперь каждое дерево учится на меньшей порции данных и признаков — деревья стали разнообразнее, предсказания устойчивее, риск запомнить шум снизился. Для CC50 добавлен более жёсткий reg_alpha (0.3), так как этот таргет имеет большой разброс и сильнее тянется к переобучению

Подбор параметров для финальной модели шаг 2

CHEMAI PROJECT



$lr=0.01$
 $n_estimators=700$

Уменьшение `learning_rate` с 0.03 до 0.01 делает каждый шаг обучения в 3 раза меньше. Модель не «проскакивает» хорошие решения и меньше цепляется за случайный шум. Увеличение числа деревьев с 300 до 700 компенсирует уменьшенный темп обучения, позволяя модели достичь той же глубины оптимизации, но с более гладкой траекторией сходимости

Подбор числа удаляемых выбросов

Оптимальное число выбросов определялось путём перебора `top_n` (число удаляемых худших остатков с каждого таргета) от 5 до 10. Для каждого значения обучалась модель с фиксированными гиперпараметрами. Однако CV-оценка не всегда совпадает с тестом Kaggle. Поэтому окончательный выбор сделан по результату на Kaggle: **`top_n=8`** (15 выбросов, 1 пересечение между таргетами) показал лучший публичный результат

Финальная модель и результат




Схема работы:

1. Удаляем 15 выбросов (top-8 остатков с каждого таргета)
2. Отбираем топ-признаки для IC50 (50) и CC50 (30)
3. Обучаем XGBoost с подобранными гиперпараметрами (lr=0.01, n=700, регуляризация из GridSearchCV) и sample_weight
4. Прогнозы в лог-шкале → обратное преобразование $\exp m1$
5. $SI = CC50 / IC50$ (защита от деления на ноль)


Результат на Kaggle (private LB):

RMSE 279.42

Топ-10 признаков IC50



Топ-10 признаков CC50



Код предсказания:

```
preds_log[target] = model.predict(X_test[top])
ic50 = np.exp(m1(preds_log['IC50'])).clip(0)
submission['SI'] = np.where(ic50 > 0.001, cc50/ic50, cc50/0.001)
```

Вывод

Финальный скор: RMSE 279.42 Команда №8 «Самые_лучшие»

Разработанная модель предсказывает три ключевых показателя для новых соединений против вируса гриппа до их синтеза:

IC50 (противовирусная активность): средний разброс предсказаний — в пределах 4-кратного отклонения от истинного значения

CC50 (токсичность для клеток): средний разброс — в пределах 3-кратного отклонения

SI (индекс селективности): вычисляется как отношение CC50 к IC50

Этой точности достаточно для этапа первичного скрининга: модель уверенно разделяет молекулы на перспективные и неперспективные. Вместо синтеза и лабораторного тестирования 1000 соединений химики могут сосредоточиться на 200–300 наиболее многообещающих — модель отсеивает заведомо неактивные или слишком токсичные варианты.

Ограничения: модель обучена на 751 молекуле одного химического класса. Для соединений с принципиально новой структурой точность может быть ниже. Рекомендуется экспериментальная валидация на независимом наборе перед внедрением в производственный процесс.

Состав команды:

Лазарев Виктор
Дублин Кирилл
Матешева Анастасия
Носульчак Елена